

Este experimento tem como objetivo demonstrar como modelos de Inteligência Artificial podem desenvolver vieses e interpretações incorretas quando treinados com conjuntos de dados limitados e estereotipados.

Para isso, foi utilizado o Teachable Machine (Google) para treinar um modelo de classificação visual contendo duas categorias:

- Estereotipo 1 — Liderança Executiva
- Estereotipo 2 — Apoio Administrativo

As imagens utilizadas no treinamento seguiram padrões estereotipados de aparência, vestimenta e contexto visual, permitindo analisar como o algoritmo interpreta incorretamente elementos fora do padrão aprendido.

O modelo foi treinado utilizando aproximadamente 20 imagens para cada categoria.


Na categoria “Estereotipo 1”, foram utilizadas imagens associadas visualmente à liderança executiva, como pessoas com roupas formais, postura séria e aparência corporativa.

Na categoria “Estereotipo 2”, foram utilizadas imagens relacionadas ao apoio administrativo, incluindo roupas mais casuais, ambientes informais e elementos considerados “menos executivos”.

Após o treinamento, foram realizados testes utilizando objetos, pessoas e cenários fora do padrão utilizado durante o treinamento para observar possíveis erros de classificação causados pelo viés dos dados.

EVIDÊNCIAS VISUAIS


Erro 1



Mesmo utilizando roupas casuais e não correspondendo ao padrão visual da categoria “Liderança Executiva”, o modelo classificou incorretamente a imagem como pertencente ao Estereotipo 1.

Isso demonstra que o algoritmo associou características específicas do treinamento a padrões superficiais de aparência.


Erro 2



Ao alterar parcialmente a vestimenta, o modelo passou a reconhecer a classificação esperada, porém sem atingir 100% de confiança.

Esse comportamento evidencia a instabilidade do modelo e sua dificuldade em interpretar corretamente indivíduos fora dos padrões predominantes do treinamento.


Erro 3



Quando um computador foi apresentado ao modelo, a classificação esperada não atingiu 100%.

Isso mostra que o algoritmo não compreende contexto ou significado real dos objetos, apenas padrões visuais aprendidos durante o treinamento.

Erro 4



Ao apontar a câmera para o teto, o modelo classificou o cenário como “Estereotipo 1” com 100% de confiança.

Esse resultado demonstra claramente como modelos enviesados podem realizar classificações completamente desconectadas da realidade quando treinados com dados limitados e pouco diversos.

MEMORIAL DE IMPACTO E ÉTICA

O viés surge quando o modelo recebe dados restritos e repetitivos, que não representam a diversidade da realidade. Ao treinar a IA com imagens baseadas em estereótipos, o algoritmo passa a associar características visuais superficiais, como roupa, gênero, postura ou aparência, a categorias sociais ou profissionais. Dessa forma, ele não compreende a função real da pessoa, apenas reproduz o padrão limitado presente no dataset.

Essa distorção gera consequências sociais importantes. Um indivíduo que não se encaixa no padrão usado no treinamento pode ser classificado de forma incorreta, marginalizado ou invisibilizado pelo sistema. Isso afeta sua autoestima, sua imagem profissional e até suas oportunidades, principalmente quando sistemas automatizados influenciam decisões em ambientes educacionais, corporativos ou de segurança.

Uma ação mitigadora é aplicar um processo de human-in-the-loop antes da implementação do modelo. Nesse processo, pessoas revisam o conjunto de dados, identificam padrões discriminatórios, verificam se há diversidade suficiente e testam o modelo com exemplos variados. A decisão final não fica apenas com a IA: humanos acompanham, corrigem e validam os resultados para garantir maior equidade e reduzir danos sociais.

CONCLUSÃO

O experimento demonstra como modelos de Inteligência Artificial podem reproduzir preconceitos e interpretações equivocadas quando treinados com conjuntos de dados limitados e enviesados.

A atividade evidencia a importância da curadoria humana, da diversidade de dados e da responsabilidade ética no desenvolvimento de sistemas baseados em IA.